

Sistema de Monitoramento e Previsao Sazonal

Concessao de Rodovias — Projeto de Portfolio

Autor	Projeto de Portfolio
Data	23/06/2026
Versao	1.0
Status	Concluido

1. Visao Geral do Projeto

Este projeto simula o sistema de dados de uma concessao de rodovias ficticia, com estrutura e complexidade proximas de um ambiente real. O objetivo foi construir uma solucao end-to-end que contempla modelagem de Data Warehouse, geracao de dados sinteticos com padroes sazonais reais, pipeline ETL, modelos de previsao de series temporais e um dashboard interativo de monitoramento.

Objetivos especificos:

- Modelar um DW em MySQL com esquema adequado para analise de series temporais
- Gerar dados sinteticos realistas cobrindo 4,5 anos de historico (jan/2022 a mai/2026)
- Implementar selecao automatica entre modelos de previsao (Prophet vs SARIMA)
- Calcular KPIs de monitoramento com alertas de desvio sazonal
- Disponibilizar os resultados em dashboard interativo com Streamlit

Stack tecnologica:

Camada	Tecnologia	Versao
Banco de dados	MySQL	8.0+
Linguagem	Python	3.13
Dashboard	Streamlit	1.58
Previsao 1	Prophet (Meta)	1.3
Previsao 2	SARIMA (statsmodels)	0.14
Visualizacao	Plotly	6.x
ORM / Conexao	SQLAlchemy + PyMySQL	2.x / 1.1
Processamento	Pandas / NumPy	3.x / 2.x

2. Arquitetura do Sistema

A solucao e organizada em cinco camadas sequenciais, onde cada camada consome a anterior e entrega dados mais refinados para a proxima:

Camada	Responsabilidade	Tecnologia
1. Dados sinteticos	Geracao de dados com padroes sazonais embutidos	SQL (procedures + RAND())
2. ETL	Extracao, transformacao e carga no DW	SQL (INSERT ... SELECT)
3. Data Warehouse	Armazenamento analitico em esquema constelacao	MySQL 8.0
4. Aplicacao	KPIs, alertas e modelos de previsao	Python 3.13
5. Dashboard	Visualizacao interativa para o usuario final	Streamlit + Plotly

Estrutura de pastas:

```
Concessao de Rodovias/  
■■■ dashboard_rodovias/  
■ ■■■ app.py # Dashboard Streamlit (entrada principal)  
■ ■■■ db.py # Conexao e queries ao DW  
■ ■■■ monitoring.py # KPIs e alertas sazonais  
■■■ sazonal_e_alertas/  
■ ■■■ forecasting.py # Selecao automatica de modelo + previsao  
■■■ previsao/  
■ ■■■ requirements.txt  
■ ■■■ secrets.toml.example  
■■■ dw_concessao_rodovias.sql # DDL do banco  
■■■ dw_populate_rodovias.sql # Dados sinteticos
```

3. Modelagem do Data Warehouse

O DW utiliza esquema em constelacao (fact constellation): quatro tabelas fato independentes compartilhando as mesmas dimensoes de tempo e trecho. Essa estrutura permite cruzar, por exemplo, picos de acidentes com picos de trafego no mesmo trecho e periodo, sem duplicar dados.

Dimensoes:

Dimensao	Granularidade / Conteudo principal
dim_tempo	Dia. Inclui estacao, feriados, ferias escolares, dia da semana — base para sazonalidade
dim_trecho	Segmentos fisicos da SP-330 com km inicial/final, tipo de piso e extensao
dim_praca_pedagio	Pracas de pedagio com tipo de sistema (manual, tag, free-flow, hibrido)
dim_categoria_veiculo	8 categorias tarifarias ANTT com coeficiente multiplicador
dim_tipo_ocorrencia	11 tipos de ocorrencia (colisoes, atropelamentos, obstaculos)
dim_tipo_manutencao	14 tipos de intervencao com grupo e criticidade

Tabelas fato:

Fato	Granularidade	Metricas principais
fact_trafego	Dia x trecho x categoria	Volume, velocidade media, indice de congestionamento
fact_acidentes	Ocorrencia individual	Obitos, feridos, tempo de atendimento, condicao climatica
fact_arrecadacao	Dia x praça x categoria	Receita bruta, receita tag, receita manual, evasao estimada
fact_manutencao	Ordem de servico	Custo por tipo (material, mao de obra, equipamento), IGP antes/depois

4. Geracao de Dados Sinteticos

Como nao havia uma base de dados real disponivel, os dados foram gerados sinteticamente em SQL puro, com padroes sazonais embutidos que simulam comportamentos reais de uma concessao de rodovias. O historico cobre 4,5 anos: janeiro de 2022 a maio de 2026.

Volume gerado:

Tabela	Registros	Logica de geracao
dim_tempo	1.633	Procedure que itera dia a dia calculando atributos sazonais
fact_trafego	65.320	1.633 dias x 5 trechos x 8 categorias — CROSS JOIN com fatores sazonais
fact_arrecadacao	39.192	1.633 dias x 3 pracas x 8 categorias — com reajuste tarifario anual de 6%
fact_acidentes	~1.400	Geracao probabilistica: RAND() < probabilidade base x amplificadores sazonais
fact_manutencao	~1.000	Ordens iniciando nas segundas; preventivas no periodo seco, corretivas pos-chuvas

Padroes sazonais embutidos:

- Veiculos leves: pico em janeiro (verao + ferias), julho (ferias de inverno) e dezembro
- Veiculos pesados: pico na safra agricola (mai-set) e queda intensa nos fins de semana e feriados
- Acidentes: 1,5x mais no verao (chuvas) e 1,6x mais em feriados
- Manutencao preventiva: concentrada em abril-setembro (periodo seco)
- Manutencao corretiva: pico em marco-maio (pos-chuvas de verao)
- Tarifa de pedagio: reajuste de ~6% ao ano entre 2022 e 2026

5. Motor de Previsao com Selecao Automatica

O modulo `forecasting.py` implementa selecao automatica de modelo entre Prophet (Meta) e SARIMA (statsmodels). Para cada serie mensal, o sistema treina ambos os modelos em um subconjunto do historico e avalia a qualidade no holdout (ultimos 6 meses) usando MAPE (Mean Absolute Percentage Error). O modelo com menor erro e retreinado com o historico completo para gerar a previsao final.

Fluxo de selecao:

1. Separar os ultimos 6 meses como conjunto de teste (holdout)
2. Treinar Prophet e SARIMA com os meses restantes
3. Calcular MAPE de cada modelo no holdout
4. Selecionar o modelo com menor MAPE
5. Retreinar o modelo vencedor com o historico completo
6. Gerar previsao para os proximos N meses (3 a 12, configuravel)

Resultados observados (horizonte de 6 meses):

Serie	Modelo escolhido	MAPE Prophet	MAPE SARIMA
Trafego (volume mensal)	Prophet	2,45%	2,76%
Acidentes (ocorrencias)	Prophet	7,55%	10,03%
Arrecadacao (receita)	SARIMA	1,33%	1,06%
Manutencao (custo)	Prophet	29,87%	36,45%

Sanitizacao numerica:

Durante o desenvolvimento, o SARIMA produziu intervalos de confianca na ordem de 10 elevado a 20 ao ser retreinado com a serie estendida — um fenomeno de instabilidade numerica comum em modelos ARIMA com parametros sazonais e series longas. Foi implementada uma funcao de sanitizacao que limita os valores previstos a uma faixa de mais ou menos 6 desvios-padrao em torno da media historica, com piso em zero, preservando a previsao central e corrigindo apenas os extremos dos intervalos de confianca.

6. Modulo de Monitoramento e Alertas

O modulo `monitoring.py` calcula tres KPIs de monitoramento para cada serie mensal, exibidos como cartoes no dashboard:

KPI	Calculo	Interpretacao
Variacao MoM	$(\text{valor_mes} / \text{valor_mes_anterior} - 1) \times 100$	Comparacao com o mes imediatamente anterior
Variacao YoY	$(\text{valor_mes} / \text{valor_mesmo_mes_ano_passado} - 1) \times 100$	Sazonalidade de longo prazo eliminada
Desvio sazonal	$(\text{valor_mes} / \text{media_historica_mesmo_mes_anos_anteriores} - 1) \times 100$	Comparacao com todos os anos anteriores no mesmo mes

Alertas contextuais:

O sistema dispara alertas automaticos quando o desvio sazonal ultrapassa um limite configuravel. A semantica e contextual — o significado de "subir" ou "descer" depende da metrica:

- Acidentes e custo de manutencao: alta acima do limite = alerta (subir e ruim)
- Receita: queda abaixo do limite = alerta (cair e ruim)
- Trafego: sem alerta por desvio (variacao natural de volume nao e critica)

Tratamento de mes incompleto:

O modulo `db.py` remove automaticamente o mes corrente da serie historica quando ele ainda nao esta completo. Sem essa logica, o ultimo mes teria apenas uma fracao dos dias do mes (ex: 21 dias em junho), distorcendo os totais mensais e a previsao que parte desse ponto.

7. Dashboard Interativo (Streamlit)

O dashboard é a interface principal do sistema, organizado em quatro abas temáticas com filtros na barra lateral:

Aba	Conteúdo
Tendencia (Trafego)	Volume total, por categoria leve/pesado, velocidade media e congestionamento
Acidentes	Total de ocorrencias, obitos, feridos e tempo medio de atendimento
Arrecadacao	Receita bruta, transacoes, receita por modalidade (tag vs manual) e evasao
Manutencao	Custo total, numero de ordens e extensao tratada (km)

Recursos interativos:

- Filtro por trecho (todos os trechos ou um segmento especifico da SP-330)
- Slider de horizonte de previsao ajustavel: de 3 a 12 meses
- Graficos com historico solido + previsao tracejada + banda de confianca de 85%
- KPIs com formatacao em padrao brasileiro (ponto como separador de milhar)
- Indicao do modelo escolhido e MAPE no teste para cada serie
- Alertas automaticos quando o desvio sazonal ultrapassa o limite configurado

Como executar:

```
# 1. Ativar ambiente virtual
venv\Scripts\activate

# 2. Instalar dependencias (primeira vez)
python -m pip install -r previsao\requirements.txt

# 3. Configurar credenciais do banco
# Editar dashboard_rodovias\.streamlit\secrets.toml

# 4. Popular o banco (primeira vez)
.\reset_db.ps1

# 5. Iniciar o dashboard
cd dashboard_rodovias
python -m streamlit run app.py
```


8. Decisoes Tecnicas e Licoes Aprendidas

Esquema constelacao vs estrela simples

Com quatro temas de analise independentes (trafego, acidentes, arrecadacao, manutencao), o esquema estrela simples forcaria uma unica tabela fato gigante com muitos campos nulos. O esquema constelacao mantem cada fato no seu contexto, facilitando queries e evitando joins desnecessarios.

Geracao de dados sinteticos em SQL puro

A escolha por SQL em vez de Python para gerar os dados foi intencional: garante que os dados estejam no banco imediatamente apos a execucao, sem necessidade de um script de carga separado. A desvantagem e que depuracao de bugs em SQL procedural e mais trabalhosa.

Selecao automatica de modelo

Em vez de fixar Prophet ou SARIMA para todas as series, o sistema avalia ambos e escolhe o melhor para cada contexto. Isso foi validado na pratica: Prophet venceu em Trafego e Acidentes (series mais regulares), SARIMA venceu em Arrecadacao (serie mais estacionaria).

Sanitizacao do intervalo de confianca

Problema real encontrado em producao: o SARIMA produziu intervalos de confianca na ordem de 10^{20} com a serie estendida. A solucao foi clipar os valores a ± 6 desvios-padrao do historico, preservando a previsao central e corrigindo apenas os extremos.

Remocao do mes incompleto

Sem essa logica, o ultimo mes (21 dias de junho/2026) aparecia com totais ~70% menores que os outros meses, distorcendo tanto os KPIs quanto o ponto de partida da previsao. A solucao foi filtrar o mes corrente automaticamente com base na data do sistema.

9. Possiveis Evolucoes

O projeto esta funcional e completo como portfolio. Possiveis evolucoes para um ambiente de producao real incluiriam:

- Integracao com fontes de dados reais (sensores de trafego, sistemas de arrecadacao)
- Pipeline de atualizacao automatica do DW (carga incremental diaria via Airflow ou cron)
- Adicao de modelo de Machine Learning supervisionado para classificacao de risco de acidente por trecho
- Implementacao de autenticacao de usuarios e controle de acesso ao dashboard
- Deploy em nuvem (AWS/GCP/Azure) com banco gerenciado e Streamlit Cloud
- Notificacoes automaticas por e-mail ou WhatsApp quando alertas forem disparados
- Mapa geografico interativo com heatmap de acidentes por km da rodovia